



XVIII Congreso Colombiano de Geología

V SIMPOSIO DE EXPLORADORES

Ciencias, sostenibilidad y sociedades futuras

— DEL 18 AL 20 DE AGOSTO DE 2021 —

Apoya:



Modelo de generación automática de capas SIG a partir de imágenes aéreas y aprendizaje profundo

John R. Ballesteros (*); Germán Sánchez-Torres, (**); John W. Branch (*)
jballes@unal.edu.co; gsanchez@unimagdalena.edu.co; jwbranch@unal.edu.co

(*) Universidad Nacional de Colombia

(**) Universidad del Magdalena

Agenda

Introducción

Trabajos relacionados

El método

Experimentos

Conclusiones

Referencias

Introducción

Archivo Editar Ver Favoritos Herramientas Ayuda

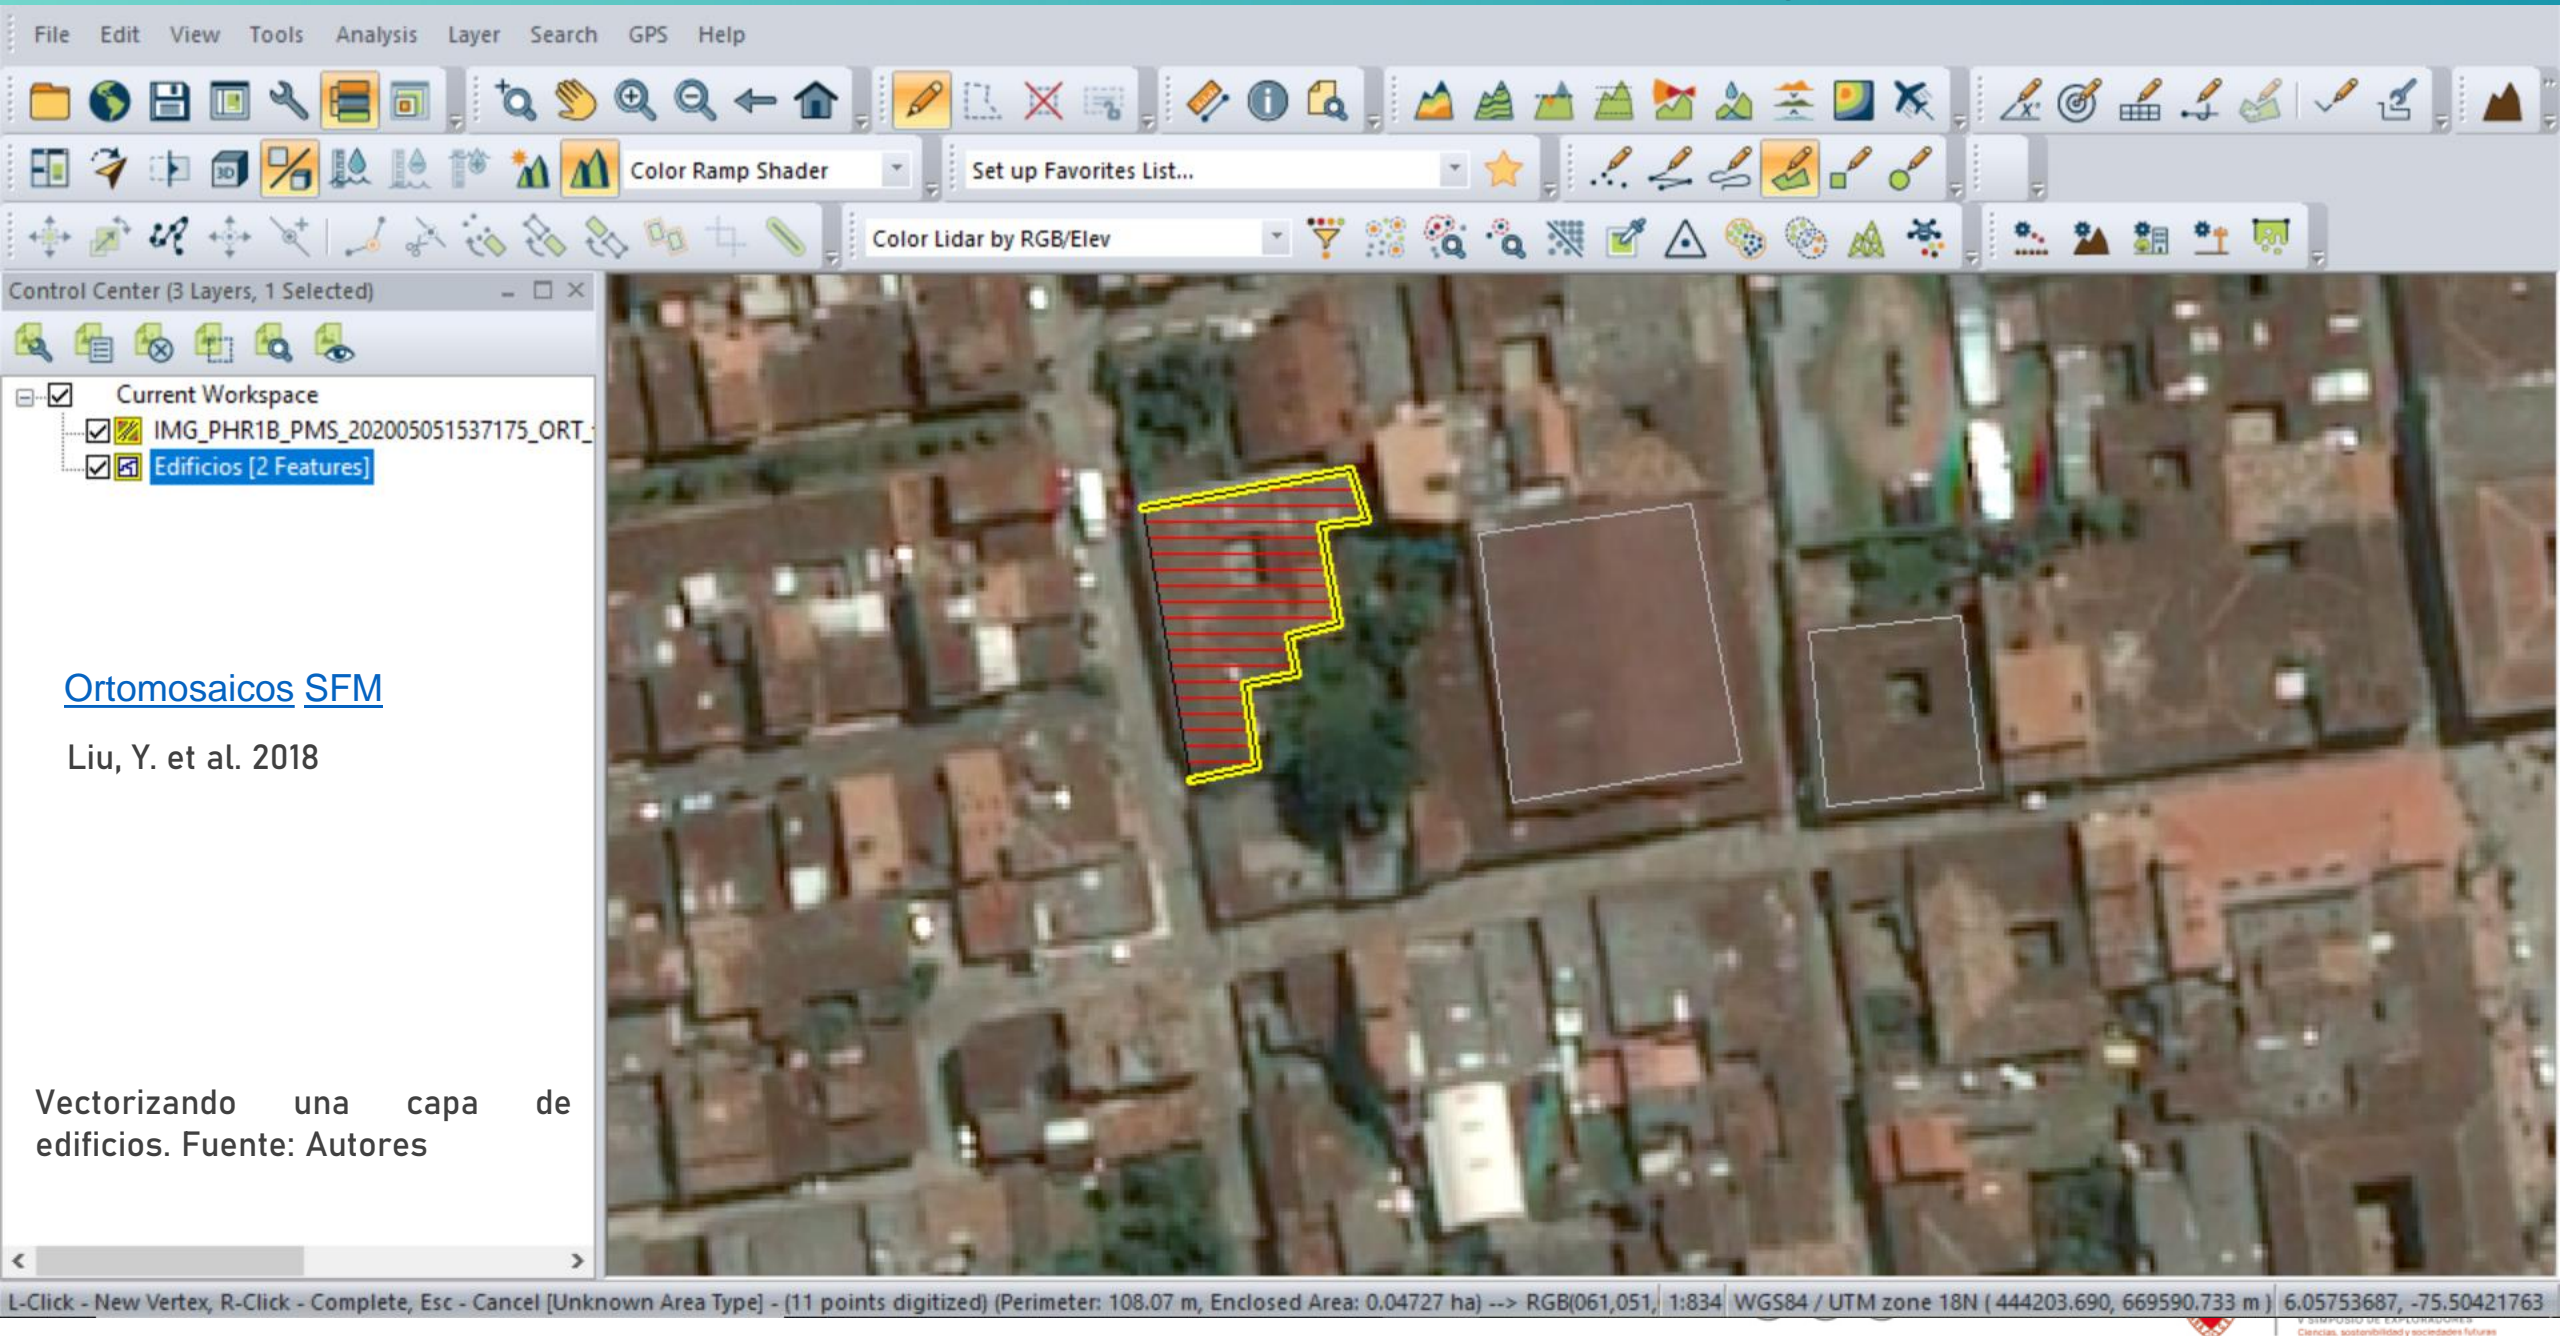


Seleccionar tipo

Código: 0x0a

Código	/	Cate...	Descri
0x0018		Agua	Arroyo
0x001f		Agua	Río
0x0001		Carreteras	Autopista
0x0002		Carreteras	Ruta principal
0x0003		Carreteras	Otra ruta
0x0004		Carreteras	Avenida
0x0006		Carreteras	Calle normal
0x0007		Carreteras	Callejón
0x000a		Carreteras	Caminero
0x000c		Carreteras	Glorieta
0x0014		Carreteras	Ferrocarril
0x0000		Desconocido	Tipo indefinido
0x001c		Limites	Límite de propiedad

Ortomosaicos escala uniforme: drone y satélite



The screenshot displays the QGIS desktop environment. The main window shows an aerial orthomosaic of a residential neighborhood. Overlaid on the image are several vector features: a yellow-outlined polygon with red diagonal hatching, and two brown-outlined polygons. The interface includes a top toolbar with various GIS tools, a left sidebar with the 'Control Center' and 'Current Workspace' panels, and a bottom status bar.

Control Center (3 Layers, 1 Selected)

- Current Workspace
 - IMG_PHR1B_PMS_202005051537175_ORT
 - Edificios [2 Features]

Ortomosaicos SFM

Liu, Y. et al. 2018

Vectorizando una capa de edificios. Fuente: Autores

L-Click - New Vertex, R-Click - Complete, Esc - Cancel [Unknown Area Type] - (11 points digitized) (Perimeter: 108.07 m, Enclosed Area: 0.04727 ha) --> RGB(061,051, 1:834 WGS84 / UTM zone 18N (444203.690, 669590.733 m) 6.05753687, -75.50421763

Extracción Automática de Capas Vectoriales

Desastres, Catastro, Planeación, Energía y Movilidad



Trabajos Relacionados

Extracción Automática de Capas SIG desde Ortomosaicos

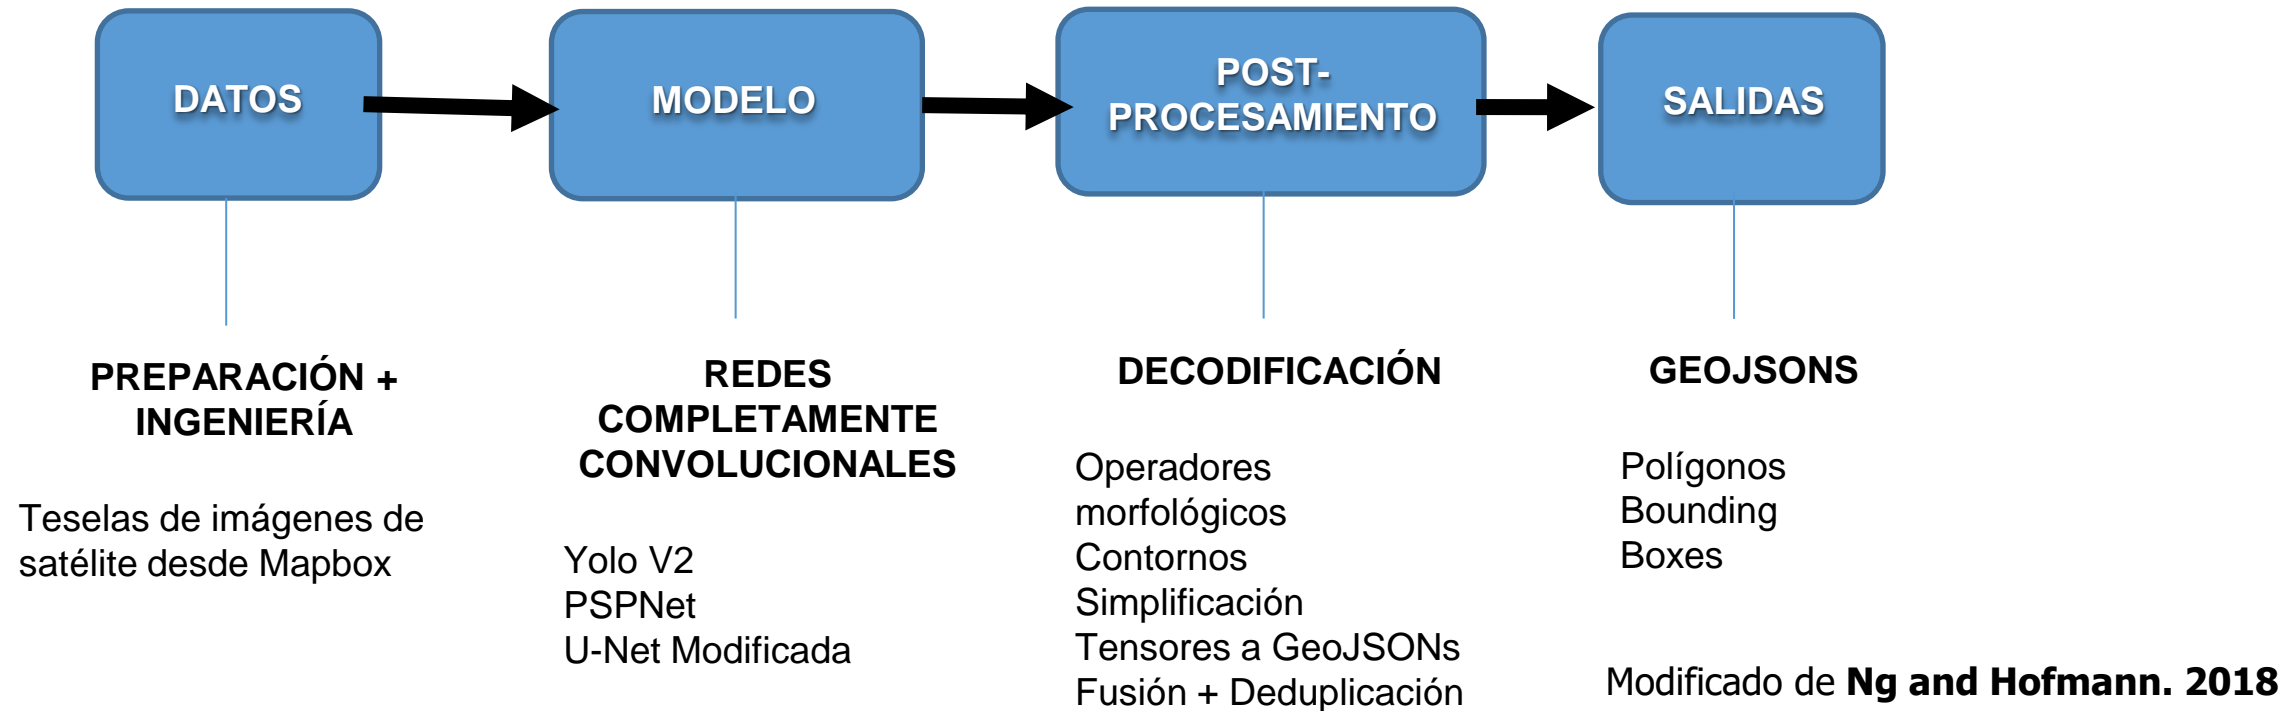
Antes de 2010	Después de 2010, Modelos basados en Deep Learning
Modelos clásicos descriptores de forma, object-based	Pixel-based, Segmentación Semántica de Imagen
Textura, Color, forma, bordes, regiones. Heurísticos-reglas , extracción de imagen	La forma es un parámetro más de los que aprende la red neuronal, Ejemplos
Semi-automáticos <i>LSB-Snakes</i>	Automáticos

Li, 1997
Crommelinck et al, 2017

Chiang, 2014
Wang, 2016
Xie et al, 2020

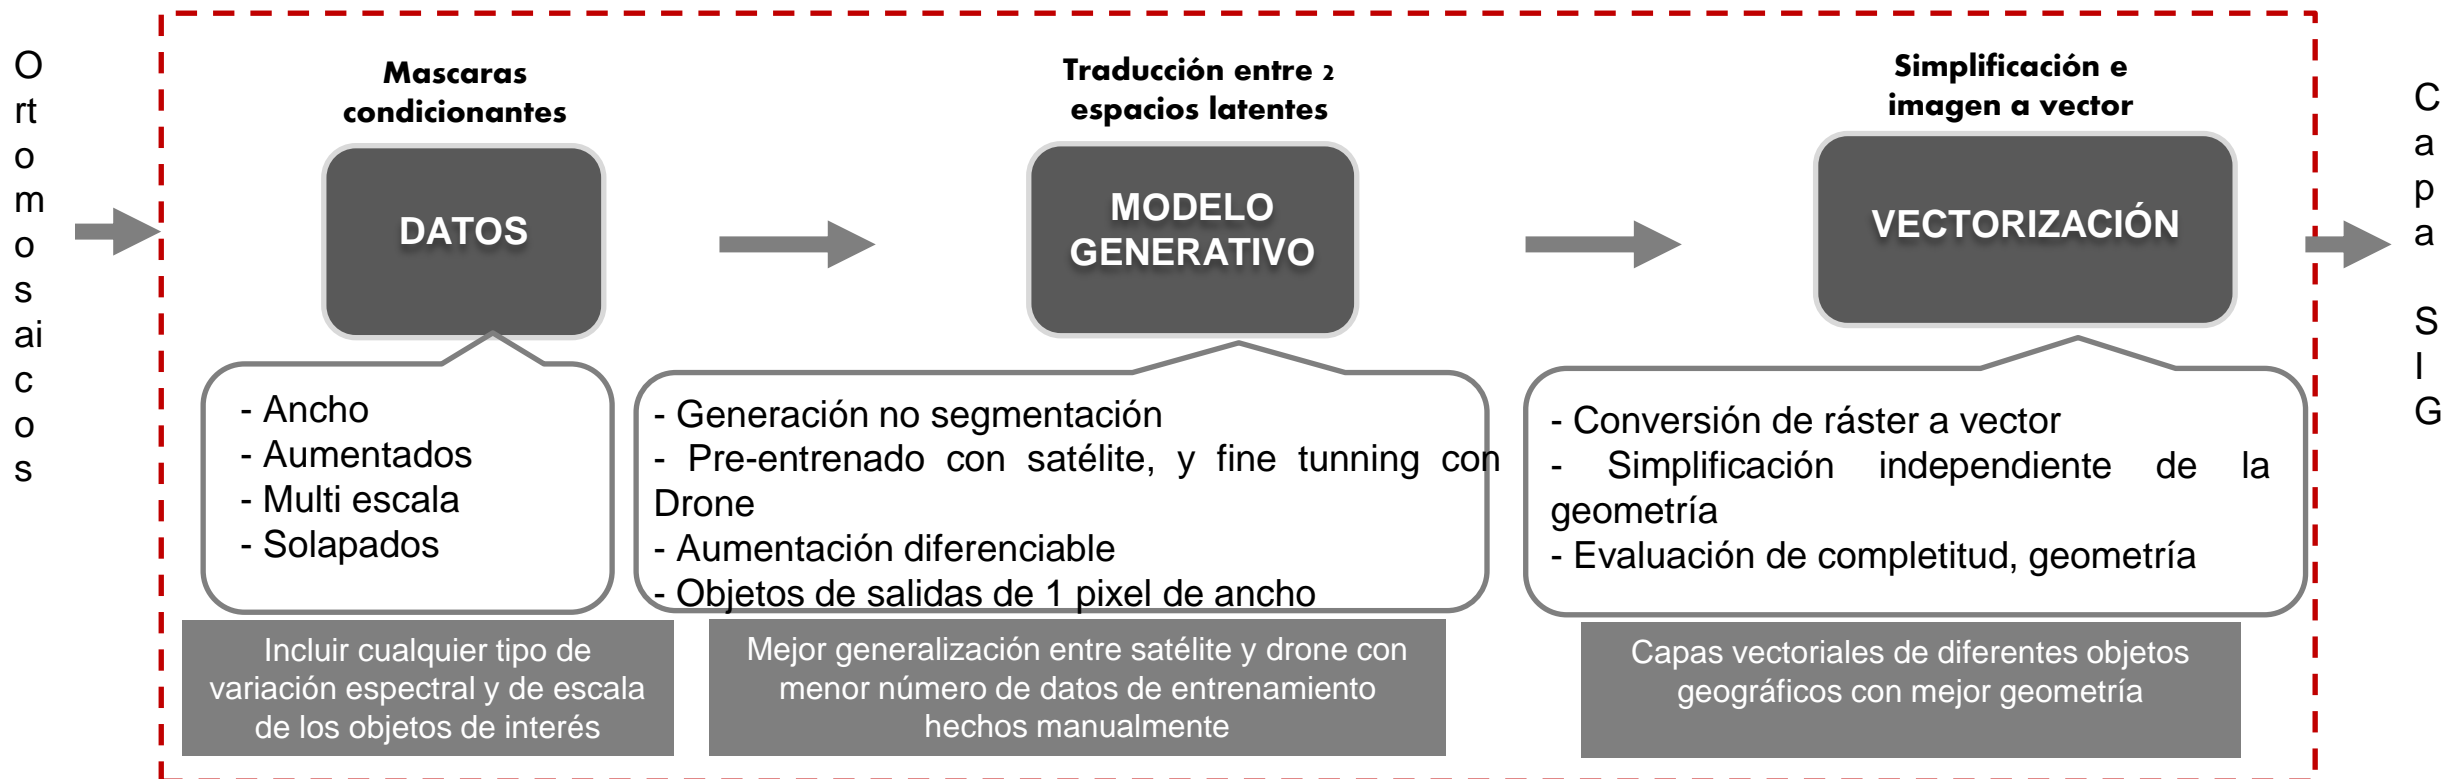
Trabajos Relacionados

RoboSat: Una arquitectura de extremo a extremo de segmentación semántica



El Método

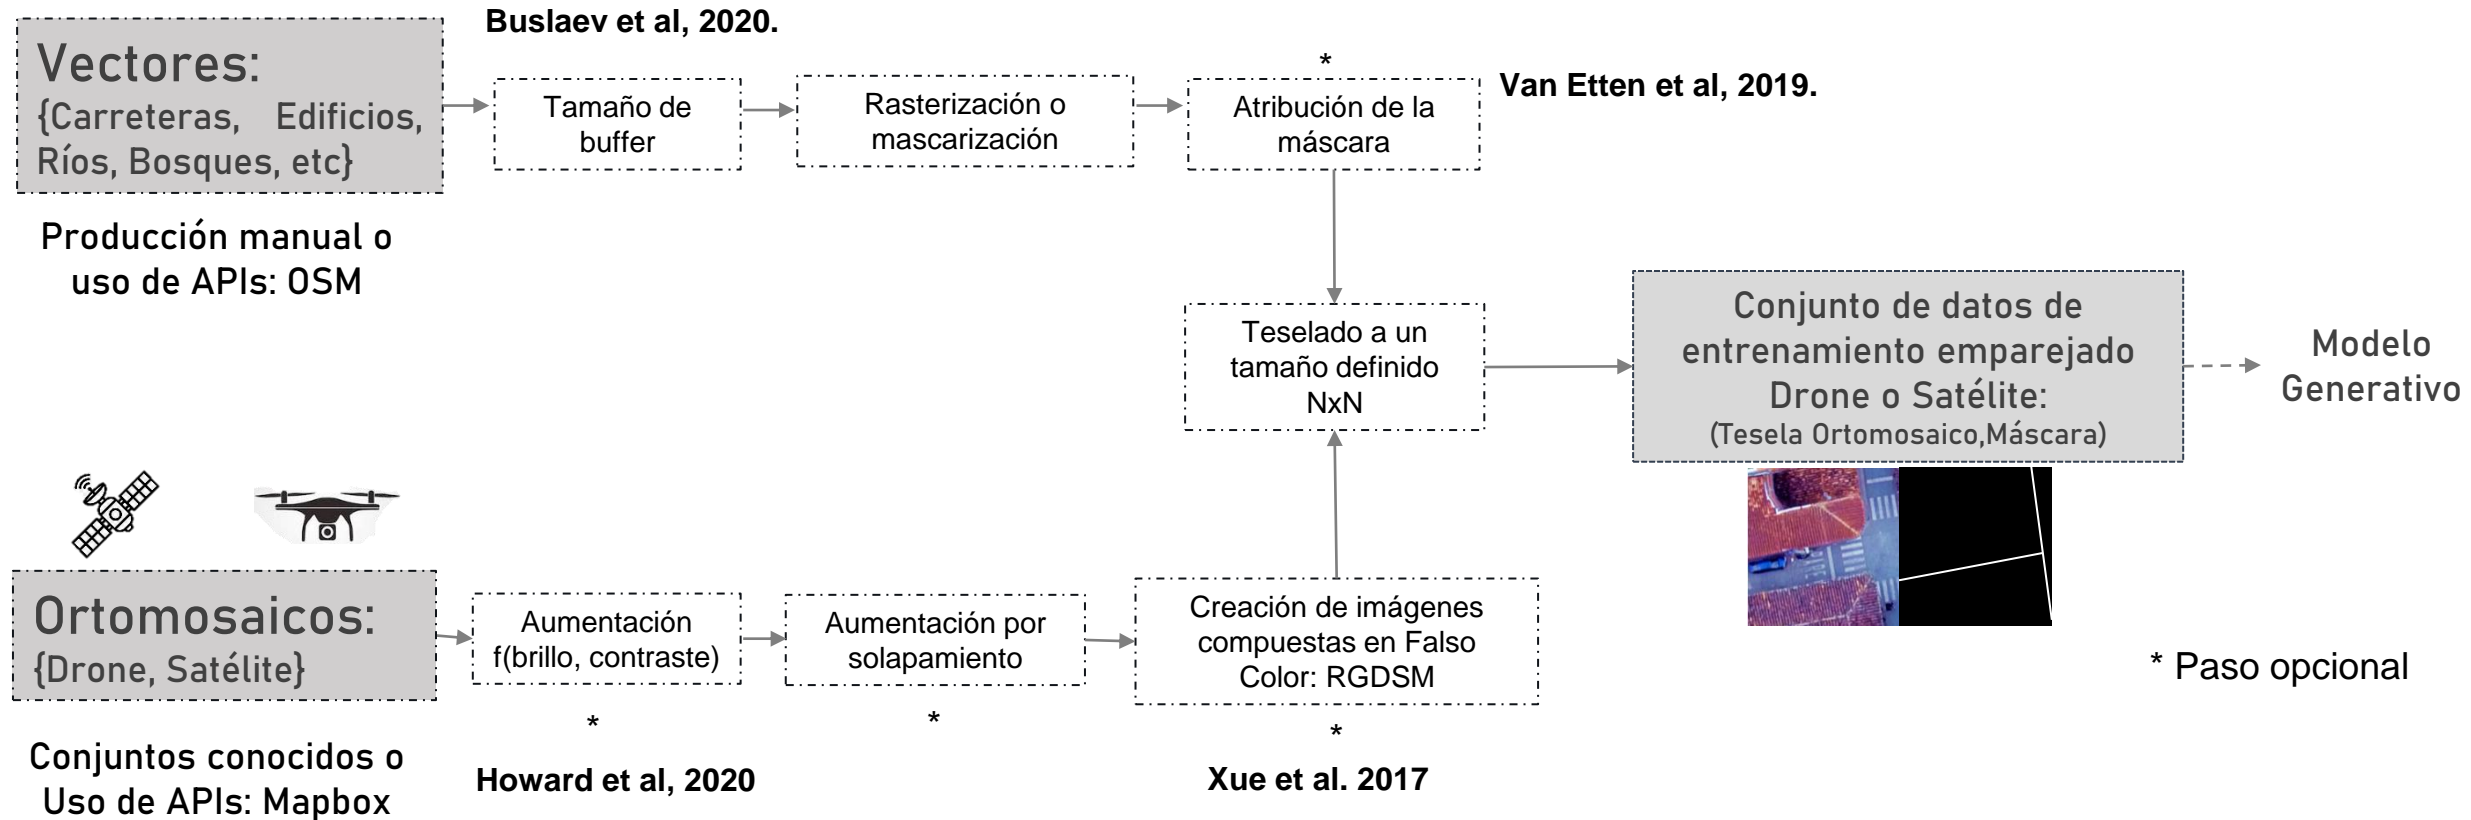
Etapas propuestas para pasar de ortomosaico a capas vector



Basado en **Ng and Hofmann. 2018**

El Método

Los Datos






Massachusetts buildings dataset, OSM, DeepGlobe, SpaceNet, Vaihingen y Potsdam (ISPRS): Different Authors and Volodymyr 2013

El Método

Los Datos:

Creación de un conjunto de entrenamiento emparejado OpenSource, GSD prom 8cm/px



Máscaras para: Carreteras, Edificios, Bosques, Parques, Parqueaderos, Ríos, Árboles, señales de tránsito (Pare, Zebra, No Parquear, Flechas)

Ortofoto mosaicos y DSM de centros poblados de Colombia: Girardota, Barbosa, El Retiro, Rionegro (incompleto), Santafe de Antioquia, San Pedro de Los Milagros, San Jerónimo, Caucasia, Andes, Urrao, Santa Barbara, Santa Rosa de Lima (Bolívar), San Juan Nepomuceno (Sucre).



@capantioquiascg



XVIII Congreso
Colombiano de Geología
Y SIMPOSIO DE EXPLORADORES
Ciencias, sostenibilidad y sociedades futuras

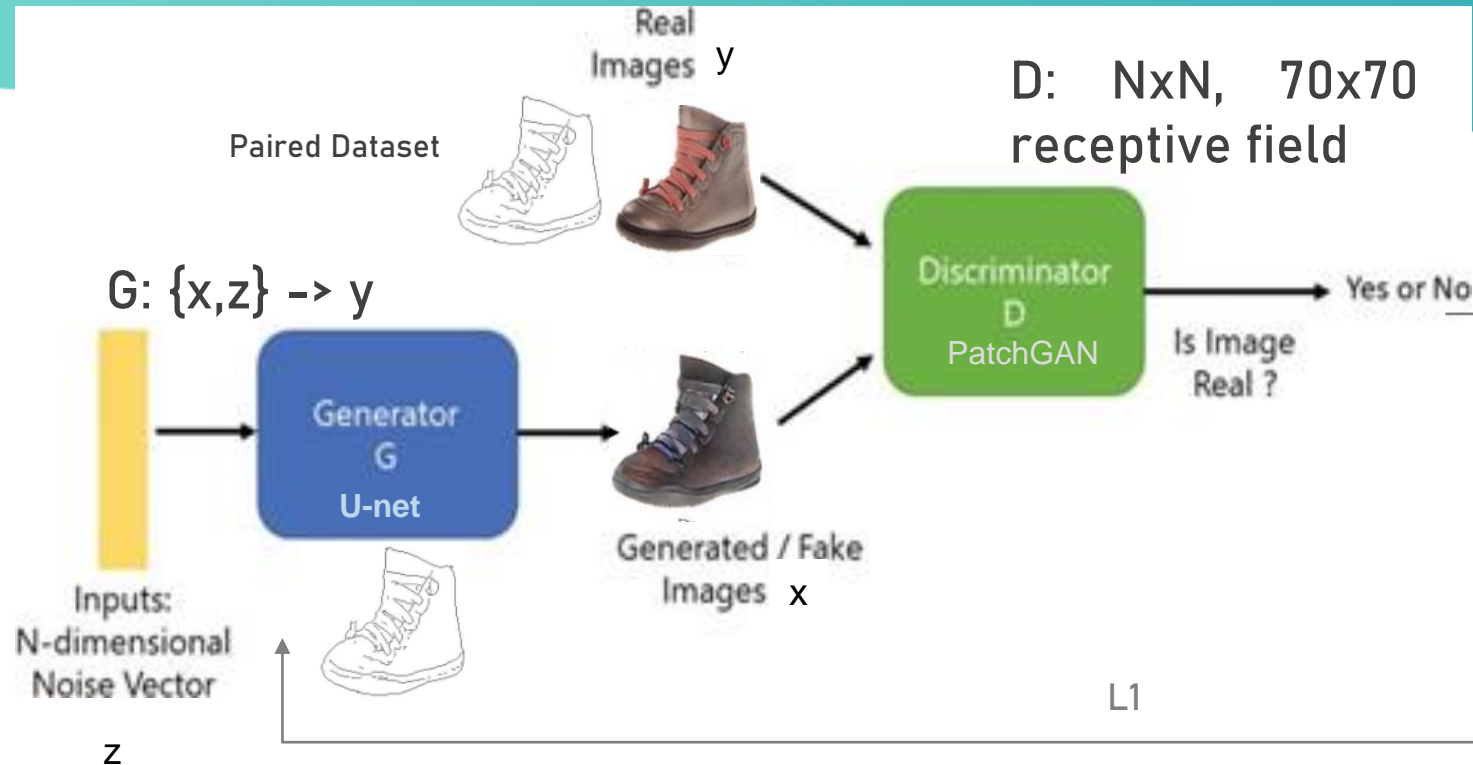
El Método

Pix2Pix. Modelo generativo condicional para traducción de imagen Isola et al. 2017



E. Latente 1, Fuente —————> E. Latente 2, Objetivo

Modelo Generativo Condicional Pix2Pix



Isola et al. 2017

$$\text{Loss}(G, D) = \mathbb{E}_{x,y}[\text{Log}D(x,y)] + \mathbb{E}_{x,z}[\text{Log}(1-D(x,G(x,z)))]$$

$$L1(G) = \mathbb{E}_{x,y,z}[||y-G(x,z)||]$$

$$L = \text{Loss}(G, D) + \lambda L1, \quad \lambda = 100, \text{ para que } G \text{ aprenda m\u00e1s r\u00e1pido que } D$$

Falencias


- Dificultad para producir conjuntos de datos emparejados
- Necesidad de muchos datos de entrenamiento. Zao et al, 2020
- Dif\u00edcil de entrenar, sobre todo al hacer aumentaci\u00f3n de datos

Se han truncado las \u00faltimas 5000 l\u00edneas:

```
>2871, d1[0.000] d2[0.000] g[4837.261]
>2872, d1[0.000] d2[0.000] g[4537.288]
>2873, d1[0.000] d2[0.000] g[4952.179]
>2874, d1[0.000] d2[0.000] g[5430.225]
>2875, d1[0.000] d2[0.000] g[8243.410]
>2876, d1[0.000] d2[0.000] g[5406.406]
>2877, d1[0.000] d2[0.000] g[3560.712]
>2878, d1[0.000] d2[0.000] g[7796.832]
>2879, d1[0.000] d2[0.000] g[8547.112]
>2880, d1[0.000] d2[0.000] g[7609.309]
>2881, d1[0.000] d2[0.000] g[4224.926]
>2882, d1[0.000] d2[0.000] g[8547.103]
>2883, d1[0.000] d2[0.000] g[9672.744]
>2884, d1[0.000] d2[0.000] g[4041.926]
>2885, d1[0.000] d2[0.000] g[4518.708]
>2886, d1[0.000] d2[0.000] g[692.497]
```


Fuente: Autores

Modelo Pix to Pix traduce imágenes de satélite y drone a mapas





Isola et al. 2017.

- Es capaz de generar las partes faltantes de los objetos de interés
- Disminuye efectos de borde
- **Multi espacial**
- Menos afectado por datos desbalanceados
- Remedia mecanismos de atención mediante el condicionamiento
- Se puede entrenar con satélite o drone



El Método

Vectorización



wikipedia.org

* Paso opcional

Experimentos

Generación de capas tipo punto (vehículos), de carreteras y de edificios a partir de imágenes de drone y de satélite:


- RGB 256x256 con diferente ancho de máscara (1px, 50cm, 1m, 2m)
- RGB + DSM 256x256= RGDSM (Falso Color) con diferente ancho de máscara (1px, 50cm, 1m, 2m)

Generación de capa de vehículos tipo punto a partir de una imagen de color compuesto RGDSM con buffer de 1 m


source_epochs_10



generated_epochs_10




target_epochs_10




source_epochs_10



generated_epochs_10



target_epochs_10




source_epochs_10




generated_epochs_10



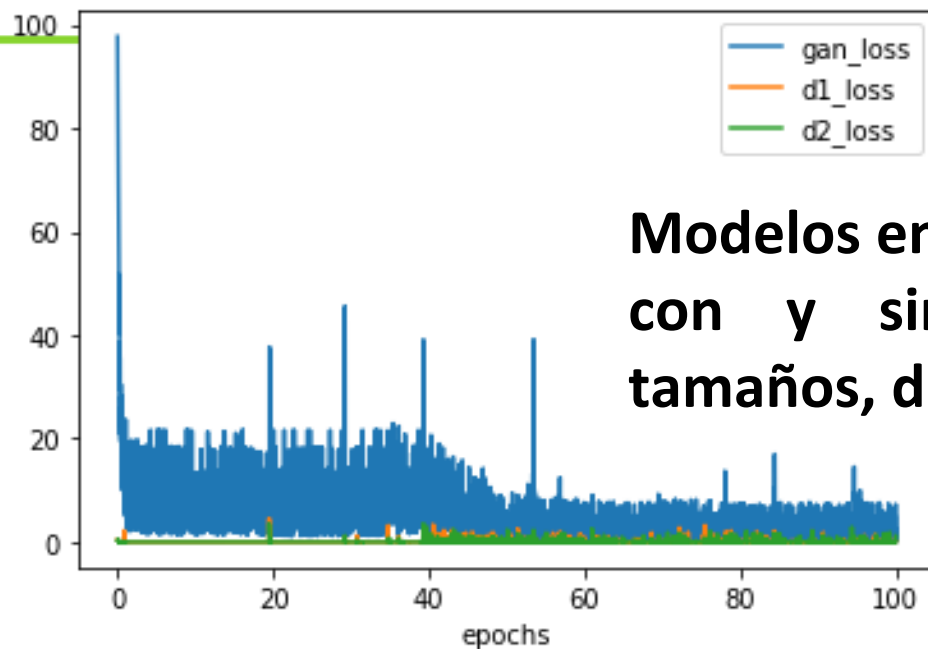
target_epochs_10



1.5m buffer for cars detection NoDSM Data

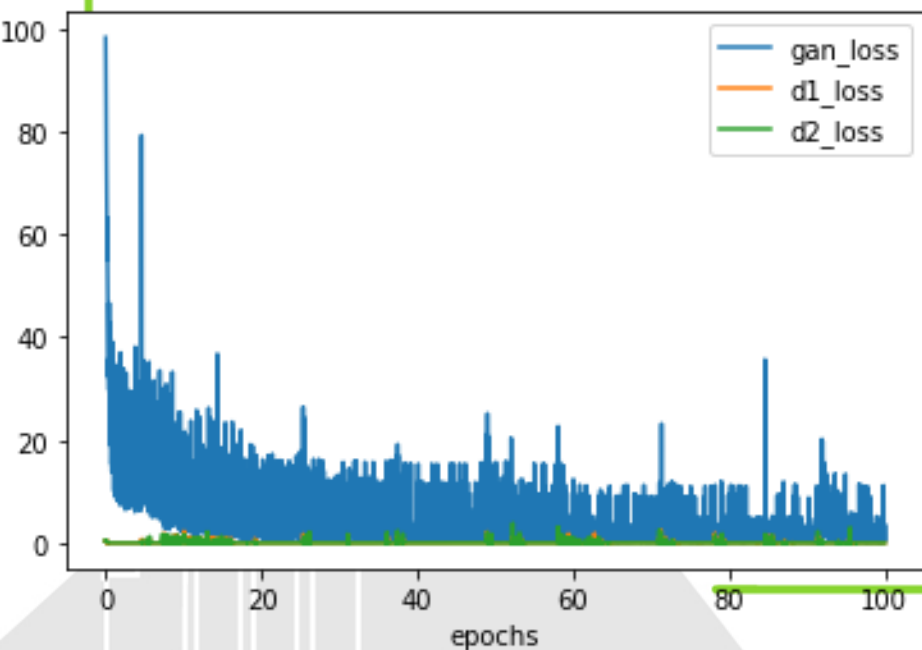


1.5m buffer for cars detection

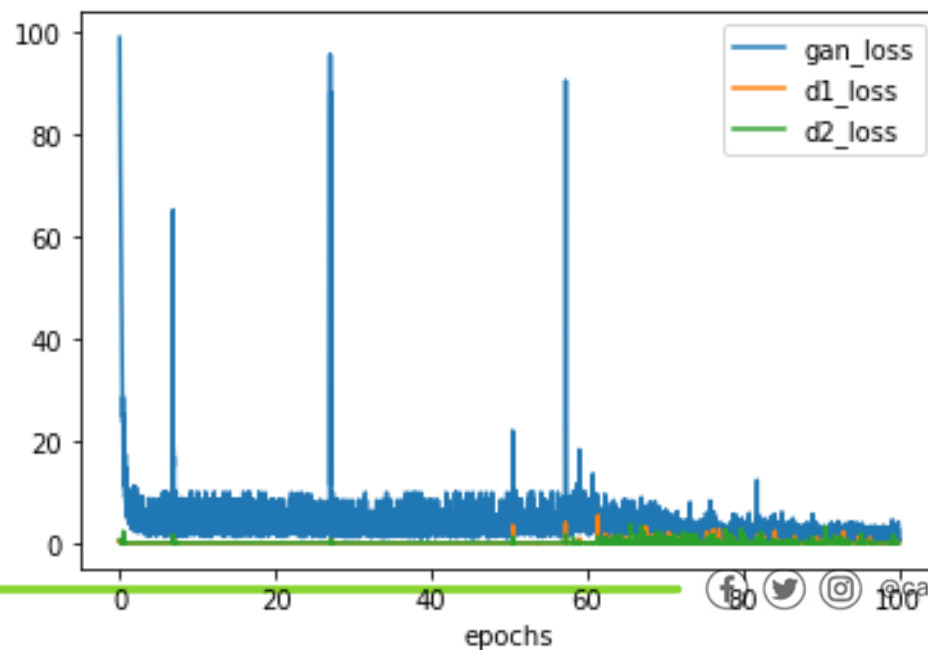


Modelos entrenados para carros con y sin DSM, diferentes tamaños, durante 100 épocas


2m buffer for cars detection




1m buffer for cars detection




RGB 1.5m de buffer de ancho de máscara



RGB 50cm de buffer de ancho de máscara




10cm buffer - Not Learning




Modelos entrenados para carreteras 50cm con y sin DSM, durante 150 épocas

No DSM data

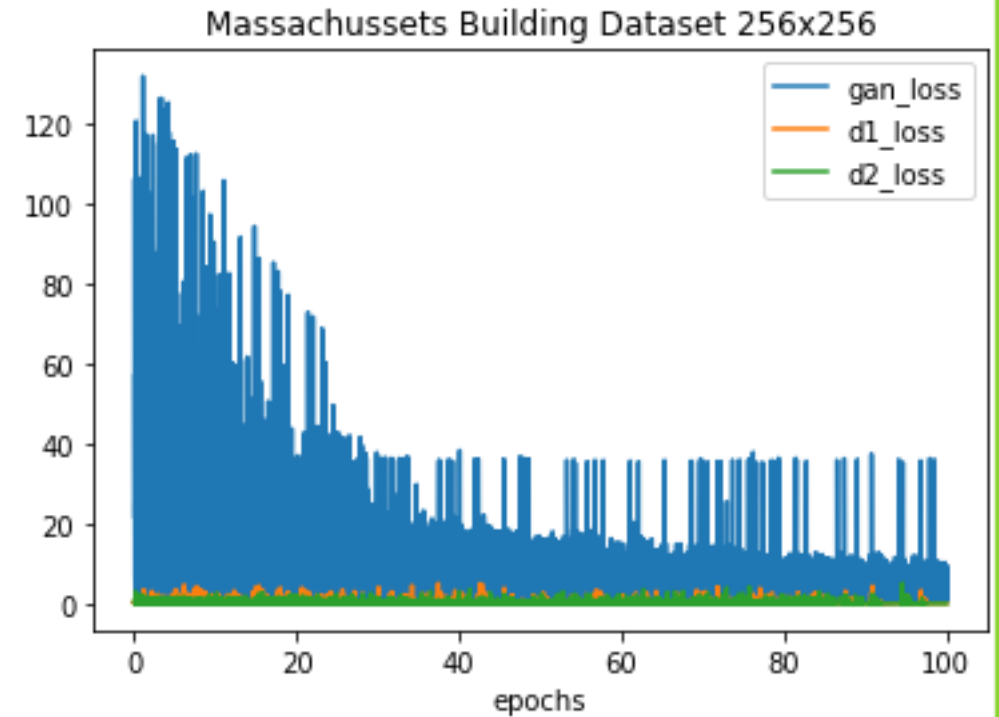



Influence of DSM data

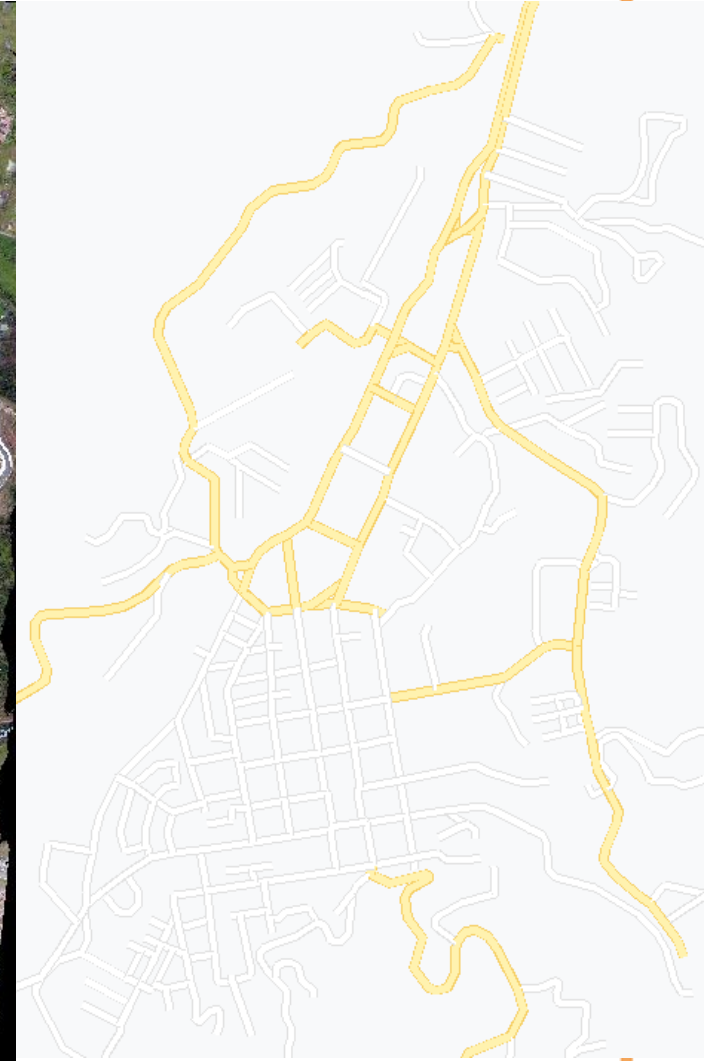



Generación de capa de edificios tipo polígonos a partir de una imagen de Satélite del conjunto de datos Massachussets (Volodymyr, 2013)

Resultados del modelo generativo con 10 épocas y 649 ejemplos



La producción automática de la capa vectorial de vías para el centro poblado del Retiro (Ant.) fue obtenida en 36 minutos, lo que manualmente tomaría alrededor de 1 mes por especialistas en SIG



@capantioquiascg



XVIII Congreso
Colombiano de Geología
Y SIMPOSIO DE EXPLORADORES
Ciencias, sostenibilidad y sociedades futuras



Conclusiones

- El modelo de generación de mapas basado en un núcleo generativo es válido para la creación de capas tipo punto, línea y polígono. Número de ejemplos y épocas.
- Integrar la información de alturas a los datos de entrenamiento creó modelos más robustos para la generación de las capas de diferente geometría.
- El tamaño de máscara de 50 px fue el de mejor desempeño para la extracción de carreteras y de carros desde las imágenes de drone.
- La capa de vías de la zona urbana del Retiro (Ant.) se obtuvo en una fracción de hora lo que tomaría semanas por personal experto.
- El modelo pix2pix (Isola et al, 2017) necesitó alrededor de 100 ejemplos y alrededor de 100 épocas para generar buenos resultados.

Trabajo Futuro

- Fine tuning del modelo generativo: pre-entrenamiento, y hiperparámetros lambda, y el tamaño de la región de activación (“patch”).
- Probar los otros pasos propuestos de la etapa de datos: máscaras solapadas, atribuidas.
- Probar otras capas: bosques, ríos.
- Evaluar más profundamente en términos de generalización y en términos de los resultados vs los obtenidos por un experto.

Referencias

1. Abdollahi, Abolfazl & Pradhan, Biswajeet & Shukla, Nagesh & Chakraborty, Subrata & Alamri, Abdullah. (2020). Deep Learning Approaches Applied to Remote Sensing Datasets for Road Extraction: A State-Of-The-Art Review. Remote Sensing. 12. 1444. 10.3390/rs12091444.
2. Adam Van Etten, Dave Lindenbaum, Todd Bacastow. SpaceNet: A Remote Sensing Dataset and Challenge Series. Computer Vision. 2019.
3. Alec Radford, et al. "Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks". ICLR 2016.
4. Al-Najjar, H.A.H.; Kalantar, B.; Pradhan, B.; Saeidi, V.; Halin, A.A.; Ueda, N.; Mansor, S. Land Cover Classification from fused DSM and UAV Images Using Convolutional Neural Networks. Remote Sens. 2019, 11, 1461. <https://doi.org/10.3390/rs11121461>
5. Arnadi Murtiyoso, Mirza Veriandi, Deni Suwardhi, Budhy Soeksmantono and Agung Budi Harto. Automatic Workflow for Roof Extraction and Generation of 3D CityGML Models from Low-Cost UAV Image-Derived Point Clouds. International Journal of Geo-Information, 2020.
6. Batra et al. Improved Road Connectivity by Joint Learning of Orientation and Segmentation. CVPR 2019.
7. Brownlee J. www.machinelearningmastery.com (accessed on 12 March 2020).
8. Bulatov, Dimitri & Häufel, Gisela & Böge, Melanie. (2016). VECTORIZATION OF ROAD DATA EXTRACTED FROM AERIAL AND UAV IMAGERY. ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences. XLI-B3. 567-574. 10.5194/isprs-archives-XLI-B3-567-2016.
9. Crommelinck, Sophie & Bennett, Rohan & Gerke, Markus & Koeva, Mila & Yang, Michael Ying & Vosselman, George. (2017). SLIC Superpixels for Object Delineation from UAV Data. ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences. IV-2/W3. 9-16. 10.5194/isprs-annals-IV-2-W3-9-2017.

Referencias

10. Crommelinck, Sophie & Bennett, Rohan & Gerke, Markus & Nex, Francesco & Yang, Michael Ying & Vosselman, George. (2016). Review of Automatic Feature Extraction from High-Resolution Optical Sensor Data for UAV-Based Cadastral Mapping. Remote Sensing. 8. 689. 10.3390/rs8080689.
11. Danyang Cao, Zhixin Chen, and Lei Gao. (2020). An improved object detection algorithm based on multi-scaled and deformable convolutional neural networks. Human Centric Computing Information Sciences. (2020). Available online: <https://doi.org/10.1186/s13673-020-00219-9>
12. Demir et al. DeepGlobe 2018: A Challenge to Parse the Earth through Satellite Images. CVPR 2018.
13. D. Marmanisa,c, K. Schindlerb , J. D. Wegnerb , S. Gallianib, M. Datcua , U. Stillac. Classification with an edge: improving semantic image segmentation with boundary detection. Elsevier, 2018.
14. Eberhard Gülch. Digital systems for automated cartographic feature extraction. Institute of Photogrammetry, University of Bonn. International Archives of Photogrammetry and Remote Sensing. 2000.
15. Fetai, Bujar & Oštir, Krištof & Fras, Mojca & Lisec, Anka. (2019). Extraction of Visible Boundaries for Cadastral Mapping Based on UAV Imagery. Remote Sensing. 11. 1510. 10.3390/rs11131510.
16. Haihong Li. Semi-automatic road extraction from satellite and aerial images. Doctoral Thesis. Swiss Federal Institute of Technology Zurich. 1997. Available online: <https://doi.org/10.3929/ethz-a-001766570>, (accessed on 21 November 2020).
17. Haowen Yan. Description Approaches and Automated Generalization Algorithms for Groups of Map Objects. ISBN 978-981-13-3678-2.

Referencias

18. Howard J. <https://course.fast.ai/part2> (accessed on 19 April 2021).
19. Hsiuhan Lexie Yang, Jiangye Yuan, Dalton Lunga, Melanie Laverdiere, Amy Rose, Budhendra Bhaduri. Building Extraction at Scale using Convolutional Neural Network: Mapping of the United States. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing (Volume: 11, Issue: 8, Aug. 2018).
20. Hui Yang, Penghai Wu, Xuedong Yao, Yanlan Wu, Biao Wang, and Yongyang Xu. Building Extraction in Very High Resolution Imagery by Dense-Attention Networks. Remote Sensing, 2018.
21. Ian Goodfellow, Yoshua Bengio and Aaron Courville. Deep Learning. MIT Press, 2016. Available online: <http://www.deeplearningbook.org>, (accessed on 16 April 2021).
22. Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio. Generative Adversarial Networks. NIPS 2014: 2672-2680.
23. Jiangye Yuan. Learning Building Extraction in Aerial Scenes Using Convolutional Networks. IEEE Transactions on Pattern Analysis and Machine Intelligence (Volume: 40, Issue: 11, Nov. 1 2018).
24. Jennings Anderson, Dipto Sarkar and Leysia Palen. (2019). Corporate Editors in the Evolving Landscape of OpenStreetMap. International Journal of Geo-Information. 2019.
25. Li, Zuoyue & Wegner, Jan & Lucchi, Aurelien. (2019). Topological Map Extraction From Overhead Images. 1715-1724. 10.1109/ICCV.2019.00180.

Referencias

26. Li, Hu, et al. Attention-Guided Multi-Scale Segmentation Neural Network for Interactive Extraction of Region Objects from High-Resolution Satellite Imagery. Remote Sensing. 2020.
27. Mathilde Caron, Hugo Touvron, Ishan Misra, Herve Jegou, Julien Mairal, Piotr Bojanowski, Armand Joulin. (2021). Emerging Properties in Self-Supervised Vision Transformers. In Press. 2021.
28. M. A. Zurbarán, P. Wightman, M. A. Brovelli. A Machine Learning Pipeline Articulating Satellite Imagery and Openstreetmap for Road Detection. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, Volume XLII-4/W14, 2019 FOSS4G 2019 – Academic Track, 26–30 August 2019, Bucharest, Romania.
29. Mohammad Pashaei, Hamid Kamangir, Michael J. Starek and Philippe Tissot. Review and Evaluation of Deep Learning Architectures for Efficient Land Cover Mapping with UAS Hyper-Spatial Imagery: A Case Study Over a Wetland. Remote Sensing, 2020.
30. Niu, Sun et al. Hybrid Multiple Attention Network for Semantic Segmentation in Aerial Images. Computer Vision and Pattern Recognition. 2020.
31. Olaf Ronneberger, Philipp Fischer, Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention (MICCAI), Springer, LNCS, Vol.9351: 234--241, 2015.
32. Phillip Isola, et al. "Image-to-Image Translation with Conditional Adversarial Networks" CVPR. 2017.
33. Paul Bolstad. GIS Fundamentals. A First Text on Geographic Information Systems. Third Edition. University of Minnesota. 2008.

Referencias

34. Salvaris M., Dean D., Tok W.H. Trends in Deep Learning. In: Deep Learning with Azure. Apress, Berkeley, CA, 2018.
35. Sahu, M. & Ohri, Anurag. (2019). VECTOR MAP GENERATION FROM AERIAL IMAGERY USING DEEP LEARNING. ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences. IV-2/W5. 157-162. 10.5194/isprs-annals. IV-2-W5-157-2019.
36. Stoian, A.; Poulain, V.; Inglada, J.; Poughon, V.; Derksen, D. Land Cover Maps Production with High Resolution Satellite Image Time Series and Convolutional Neural Networks: Adaptations and Limits for Operational Systems. Remote Sens. 2019, 11, 1986. <https://doi.org/10.3390/rs11171986>
37. Shengyu Zhao, Zhijian Liu, Ji Lin, Jun-Yan Zhu, and Song Han. (2020). Differentiable Augmentation for Data-Efficient GAN Training. NeurIPS 2020.
38. Shohei Kameyama, and Katsuaki Sugiura. (2021). Effects of Differences in Structure from Motion Software on Image Processing of Unmanned Aerial Vehicle Photography and Estimation of Crown Area and Tree Height in Forests. Remote Sensing. 2021.
39. Vijay Badrinarayanan, Alex Kendall, Roberto Cipolla. SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation, IEEE Transactions on Pattern Analysis and Machine Intelligence (Volume: 39, Issue: 12, Dec. 1 2017).
40. Virginia Ng, Daniel Hofmann. Scalable Feature Extraction with Aerial and Satellite Imagery. SCIPY 2018.
41. Volodymyr Mnih. Machine Learning for Aerial Image Labeling. Doctoral Thesis. Department of Computer Science University of Toronto. 2013.

Referencias

42. Wang, W., et al., A review of road extraction from remote sensing images, Journal of Traffic and Transportation Engineering (English Edition) (2016), Available online: <http://dx.doi.org/10.1016/j.jtte.2016.05.005> (accessed on 2 December 2020).
43. Xuran Pan, Fan Yang, Lianru Gao, Zhengchao Chen, Bing Zhang, Hairui Fan and Jinchang Ren. Building Extraction from High-Resolution Aerial Imagery Using a Generative Adversarial Network with Spatial and Channel Attention Mechanisms. Remote Sensing, 2019.
44. Yakun Xie, Jun Zhu, Yungang Cao, Dejun Feng, Minjun Hu, Weilian Li, Yunhao Zhang, and Lin Fu. Refined Extraction Of Building Outlines From High-Resolution Remote Sensing Imagery Based on a Multifeature Convolutional Neural Network and Morphological Filtering. IEEE, 2020.
45. Yao-Yi Chiang, Stefan Leyk, and Craig A. Knoblock. A survey of digital map processing techniques. ACM Comput. Surv. 47, 1, Article 1 (April 2014), 44 pages. Available online: <http://dx.doi.org/10.1145/2557423> (accessed on 20 March 2021).
46. Yi, Terence J., "Semantic Segmentation of Aerial Imagery using U-Nets" (2020). Theses and Dissertations. 3593.
47. Yilang Shen et al. A New Approach to Line Simplification Based on Image Processing: A Case Study of Water Area Boundaries. International Journal of Geo-Information. 2018.
48. Yongyang Xu, Liang Wu, Zhong Xie, and Zhanlong Chen. Building Extraction in Very High Resolution Remote Sensing Imagery Using Deep Learning and Guided Filters. Remote Sensing, 2017.
49. Zhaoli Hong, Dongping Ming, Keqi Zhou, Ya Guo, and Tingting Lu. Road Extraction from a High Spatial Resolution Remote Sensing Image Based on Richer Convolutional Features. IEEE 2018.

John R. Ballesteros



jballes@unal.edu.co

<https://www.linkedin.com/in/john-ballesteros-28bb7063/>

Gidia
Grupo de I+D
en Inteligencia Artificial



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Gracias



@capantioquiascg




XVIII Congreso
Colombiano de Geología
Y SIMPOSIO DE EXPLORADORES
Ciencias, sostenibilidad y sociedades futuras